

Proyecto Final Tópicos D

Aplicación y evaluación comparativa de Árboles de Decisión y Random Forest

Integrantes: Felipe Cárcamo O. fcaroyar@umag.cl

Christofer Gutiérrez P chgutier@umag.cl

Asignatura: Tópicos D

Fecha: 6 de julio del 2026

Índice

Índice.....	1
1. Introducción y definición del problema.....	2
1.1. Contexto.....	2
1.2. Objetivos.....	2
2. Descripción y análisis del conjunto de datos.....	2
2.1. Origen y atributos generales del dataset.....	2
2.2. Diccionario de variables clínicas.....	3
2.3. Análisis exploratorio de datos.....	3
Limpieza de datos y manejo de registros duplicados.....	4
Análisis estadístico del balance de clases.....	4
3. Metodología y diseño experimental.....	5
3.1. División de tres conjuntos.....	5
3.2. Preprocesamiento y escalado de atributos.....	5
3.3. Algoritmos seleccionados e hiperparámetros regulados.....	6
Modelo 1: Árbol de Decisión (Decision Tree):.....	6
Modelo 2: Random Forest.....	6
4. Experimentación y resultados.....	7
4.1. Evaluación de modelos base y diagnóstico de overfitting.....	7
4.2. Sintonización Estructurada de Hiperparámetros.....	8
Ajuste en el Árbol de Decisión Regularizado.....	8
Ajuste en el Random Forest Regularizado.....	8
4.3. Análisis visual e interpretación clínica del árbol de decisión.....	8
5. Evaluación final y discusión.....	10
5.1. Desempeño Definitivo en el Conjunto de Prueba (Test).....	10
Análisis crítico de las métricas clínicas.....	10
5.2. Tabla Comparativa General de Experimentos.....	11
5.3. ¿Qué se gana y que se pierde?.....	12
5.4. Implicaciones Éticas y Limitaciones del Modelo en el Área de la Salud.....	12
6. Conclusiones.....	13
6.1. Cumplimiento de Objetivos y Validación Metodológica.....	13
6.2. Hallazgos Técnicos sobre el Control de Overfitting.....	13
6.3. Recomendación del Modelo y Escalabilidad.....	13

1. Introducción y definición del problema

1.1. Contexto

Las enfermedades cardiovasculares representan una de las principales causas de morbilidad y mortalidad a nivel global, impactando severamente a los sistemas de salud. El diagnóstico oportuno de afecciones cardíacas es un desafío crítico, dado que muchos de los síntomas iniciales pueden ser sutiles o confundirse con otras condiciones fisiológicas.

La integración de herramientas tecnológicas capaces de procesar de manera simultánea un conjunto diverso de atributos clínicos, tales como la presión arterial, los niveles de colesterol, la frecuencia cardíaca máxima y registros electrocardiográficos, ofrece una oportunidad para agilizar la identificación de pacientes en situación de riesgo, permitiendo priorizar de forma eficiente la asignación de exámenes de alta complejidad.

1.2. Objetivos

- Desarrollar un flujo metodológico de ciencia de datos que asegure la limpieza, el preprocesamiento y el escalado correcto de los parámetros clínicos recopilados.
- Entrenar y evaluar de manera comparativa dos algoritmos de aprendizaje supervisado: un Árbol de Decisión (Decision Tree) y un Bosque Aleatorio (Random Forest).
- Mitigar de forma efectiva el impacto del sobreajuste mediante la experimentación estructurada con hiperparámetros de regularización en ambos algoritmos.
- Garantizar la robustez metodológica del sistema mediante el aislamiento estricto de un conjunto de prueba para la validación final del modelo ganador.

2. Descripción y análisis del conjunto de datos

2.1. Origen y atributos generales del dataset

El conjunto de datos utilizado en este proyecto es el “Heart Disease Dataset”, obtenido del repositorio de Kaggle, el cual recopila registros de pacientes evaluados en entornos clínicos para determinar la presencia de anomalías en el corazón.

2.2. Diccionario de variables clínicas

Para comprender la naturaleza del problema y revisar el comportamiento de los modelos, es indispensable estructurar un diccionario técnico de las variables que componen la matriz de características X. A continuación, se detallan los atributos del dataset:

Variable	Tipo de dato	Escala/Valores	Descripción
age	Numérico continua	Años	Edad cronológica del paciente.
sex	Categoría binaria	1 = Masculino 0 = Femenino	Sexo biológico del individuo.
cp	Categoría ordinal	0 a 3	Tipo de dolor torácico.
trestbps	Numérico continua	mm Hg	Presión arterial sistólica en reposo al momento del ingreso hospitalario.
chol	Numérico continua	mg/dl	Colesterol sérico total.
fbs	Categoría binaria	1 = ≥ 120 mg/dl 0 = ≤ 120 mg/dl	Azúcar en sangre en ayunas.
restecg	Categoría discreta	0 a 2	Resultados del electrocardiograma en reposo.
thalach	Numérico continua	lpm (latidos por min)	Frecuencia cardíaca máxima alcanzada por el paciente durante una prueba de esfuerzo físico.
exang	Categoría binaria	1 = Sí 0 = No	Angina inducida por el ejercicio. Registra si el esfuerzo físico desencadenó dolor de pecho por déficit de oxigenación.
oldpeak	Numérico continua	Milímetros (mm)	Depresión del segmento ST inducida por el ejercicio en comparación con el reposo.
slope	Categoría ordinal	0 a 2	Pendiente del segmento ST durante el esfuerzo máximo.
ca	Numérico discreta	0 a 4	Número de vasos sanguíneos principales (coronarias) coloreados mediante fluoroscopia.
thal	Categoría discreta	1 a 3	Resultado de la gammagrafía cardíaca.

2.3. Análisis exploratorio de datos

El Análisis Exploratorio de Datos es el paso fundamental para revisar cómo vienen nuestros datos antes de pasárselos a cualquier modelo. En este proyecto, nos enfocamos en limpiar la muestra y revisar que las clases estuvieran bien distribuidas.

Limpieza de datos y manejo de registros duplicados


Antes de entrenar los modelos, realizamos un proceso de revisión y limpieza en el dataset. Al revisar las columnas, confirmamos que no existían valores nulos o celdas vacías, por lo que no hizo falta inventar ni rellenar datos usando promedios.

Sin embargo, un hallazgo muy importante fue la detección de registros duplicados. Esto sucede debido a que este dataset es una extensión artificial basada en el conjunto de datos de Cleveland (el cual cuenta originalmente con alrededor de 303 registros únicos). Para aumentar el volumen de datos de forma sintética, se replicaron filas idénticas de pacientes.

Para Machine Learning, dejar estos datos duplicados es un problema grave y por eso los eliminamos. Si permitimos que haya filas idénticas en el dataset, se rompe la independencia de los datos. Al momento de dividir las muestras, una de las copias podría quedar en el conjunto de entrenamiento y la otra en el de validación. Esto provocaría que el modelo “haga trampa” de forma involuntaria, ya que estaría evaluándose con un paciente exactamente igual al que usó para estudiar. Al borrarlos, nos aseguramos de que cada paciente sea único y que las métricas finales sean honestas.

Análisis estadístico del balance de clases

Para revisar el desbalance dentro del dataset, generamos un gráfico de barras cuantitativo para evaluar la distribución real de la variable target.



Los resultados obtenidos y respaldados visualmente por el gráfico revelaron que la variable objetivo se distribuye de la siguiente manera:

- Pacientes Sanos (Clase 0): Representan el 45.70% de la muestra total.
- Pacientes Enfermos (Clase 1): Constituyen el 54.30% restante del dataset.

Esta distribución cercana al 50/50 confirma que el dataset se encuentra completamente balanceado. Al no haber una asimetría marcada entre sanos y enfermos, garantizamos que la métrica de Accuracy será un indicador confiable y real del rendimiento de los modelos, sin necesidad de aplicar técnicas artificiales para balancear los datos.

3. Metodología y diseño experimental

3.1. División de tres conjuntos

En este proyecto, aplicamos una estrategia rigurosa dividiendo los datos originales en tres conjuntos totalmente independientes:

1. **Conjunto de Entrenamiento (Train):** Corresponde al 60% de los datos. Aquí es donde los modelos analizan las características de los pacientes para aprender a asociar los síntomas con la presencia o ausencia de una enfermedad cardíaca.
2. **Conjunto de Validación (Validation):** Corresponde al 20% de los datos. Se utiliza exclusivamente durante la etapa de experimentación para probar diferentes configuraciones de los modelos y detectar si el algoritmo está sufriendo de overfitting.
3. **Conjunto de Prueba (Test):** Corresponde al 20% restante de los datos. Permaneció completamente guardado durante toda la fase de diseño. Solo se utilizó una única vez al final del proyecto con el modelo ganador para simular cómo se comportaría la inteligencia artificial ante pacientes reales del mundo exterior.

3.2. Preprocesamiento y escalado de atributos

Los datos clínicos de los pacientes vienen en escalas numéricas muy diferentes. Por ejemplo, la edad se mueve en rangos de décadas, el colesterol en cientos de unidades, mientras que variables como oldpeak usan decimales pequeños. Para estandarizar estas magnitudes, aplicamos una técnica de normalización llamada StandardScaler, la cual transforma todas las columnas numéricas para que tengan una media de 0 y una desviación estándar de 1.

Es importante destacar un aspecto teórico clave de los modelos a utilizar: los algoritmos basados en árboles de decisión y bosques aleatorios son invariantes al escalado de características. Esto significa que estos modelos realizan cortes en los datos mediante reglas lógicas independientes

para cada síntoma, por lo que el tamaño de los números no altera sus decisiones ni su rendimiento final.

A pesar de esta propiedad, decidimos aplicar el escalado siguiendo la pauta general del proyecto por dos razones principales:

1. **Cumplimiento metodológico:** Permite incorporar de forma rigurosa la etapa de preprocesamiento dentro del ciclo de vida general del desarrollo del software.
2. **Flexibilidad y escalabilidad del sistema:** Al dejar el set de datos ya normalizado y estructurado en una “escala común”, el proyecto queda preparado para el futuro. Si se decidiera integrar otros modelos de Machine Learning, esos algoritmos podrían requerir que los datos estén escalados para no fallar. Gracias a este paso extra, cambiar o añadir un nuevo modelo no requerirá reescribir ni modificar la lógica de preparación de los datos.

3.3. Algoritmos seleccionados e hiperparámetros regulados

De acuerdo con lo solicitado dentro de la pauta, seleccionamos dos algoritmos basados en estructuras de árboles.

Modelo 1: Árbol de Decisión (Decision Tree):

Un Árbol de Decisión es un modelo secuencial que divide a los pacientes creando reglas lógicas en forma de preguntas (por ejemplo: “¿El paciente tiene un tipo de dolor torácico mayor a 0.5?”). El algoritmo decide qué pregunta hacer en cada nivel utilizando una métrica matemática llamada Impureza de Gini, la cual mide qué tan mezclados están los pacientes sanos y enfermos en un grupo. El objetivo del árbol es hacer cortes sucesivos hasta lograr que los grupos finales sean lo más puros posibles.

- Hiperparámetro regulado (`max_depth`): Por defecto, el árbol viene configurado con `max_depth=None`, lo que significa que el árbol crecerá de forma ilimitada hasta memorizar cada caso. Para controlar el overfitting, experimentamos limitando de forma manual la profundidad máxima del árbol a un nivel de 3 (`max_depth=3`), forzando al algoritmo a crear reglas de diagnóstico mucho más sencillas y generales.

Modelo 2: Random Forest

Random Forest es un modelo avanzado que pertenece a la familia del aprendizaje por ensamble. En lugar de confiar en el veredicto de un único árbol de decisión, este algoritmo crea todo un “bosque” de múltiples árboles en paralelo. Para asegurar que los árboles no sean idénticos entre

sí, el modelo aplica dos técnicas aleatorias: entrena cada árbol con un grupo de pacientes mezclado al azar y selecciona un subconjunto diferente de síntomas médicos para cada corte de rama. Al final, cuando ingresa un paciente nuevo, todos los árboles votan y el bosque emite el diagnóstico por mayoría.

- Hiperparámetros regulados (`n_estimators` y `max_depth`): Para mejorar el rendimiento del bosque base y evitar que replicara el overfitting, modificamos dos parámetros de forma simultánea. Sintonizamos el modelo elevando la cantidad de árboles a 200 (`n_estimators=200`) para dar mayor estabilidad al bosque, y restringimos la profundidad de cada uno de sus árboles internos a un máximo de 3 niveles (`max_depth=3`).

4. Experimentación y resultados

4.1. Evaluación de modelos base y diagnóstico de overfitting

La primera etapa de la experimentación consistió en entrenar tanto el Árbol de Decisión como el Random Forest utilizando sus configuraciones predeterminadas (parámetros por defecto de scikit-learn), sin imponer ninguna restricción a su crecimiento estructural. El objetivo de este paso fue establecer una línea base de rendimiento y evaluar el comportamiento nativo de ambos algoritmos.

Los resultados obtenidos en el conjunto de entrenamiento y en el de validación arrojaron métricas críticas:

- Árbol de Decisión Base: Alcanzó un Accuracy de 1.0 (100%) en el conjunto de entrenamiento, mientras que en el conjunto de validación descendió a 0.75 (75%).
- Random Forest Base: Replicó exactamente el mismo comportamiento, obteniendo un Accuracy de 1.0 (100%) en entrenamiento y un 0.75 (75%) en validación.

Un rendimiento perfecto del 100% en la etapa de estudio es una señal clara de overfitting. Al dejar el parámetro `max_depth=None`, permitimos que el árbol individual y los árboles internos del bosque crecieran de forma ilimitada, creando ramas tan específicas que terminaron por memorizar el ruido, los valores atípicos y las particularidades exactas de los pacientes de entrenamiento.

Al enfrentarse a los datos del conjunto de validación, el rendimiento cayó drásticamente al 75%. Esto demostró que ambos modelos base carecían de una capacidad real de generalización, lo que

en un entorno médico es inaceptable, ya que el sistema fallaría al intentar diagnosticar a nuevos usuarios.

4.2. Sintonización Estructurada de Hiperparámetros

Para solucionar el problema del overfitting, se procedió a aplicar técnicas de regularización e hiperparametrización sobre ambos algoritmos, buscando acotar la complejidad de sus estructuras para obligarlos a aprender patrones generales en lugar de memorizar casos particulares.

Ajuste en el Árbol de Decisión Regulado

Se modificó el hiperparámetro de profundidad máxima, limitando el modelo a un tope de tres niveles (`max_depth=3`). Tras aplicar esta restricción, las métricas de Accuracy se reconfiguraron:

- Accuracy en Entrenamiento: 0.8729 (87.29%)
- Accuracy en Validación: 0.7666 (76.66%)

Aunque el rendimiento en el conjunto de estudio bajó del 100% al 87.29%, el rendimiento con los pacientes de validación subió al 76.66%. Al acortar la distancia entre ambas métricas, confirmamos que el control de la profundidad logró frenar con éxito el overfitting del modelo individual.

Ajuste en el Random Forest Regulado

Para potenciar el rendimiento se modificaron dos hiperparámetros de manera simultánea: se fijó la profundidad de cada árbol en tres niveles (`max_depth=3`) y se aumentó la cantidad total de estimadores a 200 árboles (`n_estimators=200`). Las nuevas métricas obtenidas fueron:

- Accuracy en Entrenamiento: 0.9005 (90.05%)
- Accuracy en Validación: 0.8333 (83.33%)

Esto entregó el rendimiento más alto de toda la fase experimental. Al promediar los veredictos de 200 árboles independientes y controlados, el Random Forest neutralizó las desviaciones de los árboles individuales. El modelo no solo controló el overfitting, sino que alcanzó un sólido 83% de precisión con datos nuevos, consolidándose como el candidato óptimo para el proyecto.

4.3. Análisis visual e interpretación clínica del árbol de decisión

Una de las mayores ventajas del Árbol de Decisión Regulado es su transparencia. Gracias al gráfico generado en el notebook mediante la función `plot_tree` de Matplotlib, es posible realizar

una revisión paso a paso del árbol, trazando la lógica exacta que utiliza la inteligencia artificial para evaluar a un paciente.

Estructura del Arbol de Decision Regulado (max_depth=3)



A partir del análisis jerárquico del gráfico, se detallan los siguientes niveles de decisión:

1. El Nodo Raíz (Nivel 0 - Atributo cp): El algoritmo determinó de forma estadística que el tipo de dolor torácico (cp - Chest Pain type) es la variable clínica más importante y discriminadora del dataset para iniciar la clasificación. Si el paciente presenta un dolor torácico bajo o asintomático (valor de la condición verdadero), la lógica se desplaza hacia la rama izquierda; si el dolor es severo o atípico, se desplaza hacia la derecha.
2. Nivel de División 1 (Atributos thal y oldpeak):
 - Para el grupo de la izquierda (pacientes con dolor torácico leve), el árbol utiliza como factor de desempate la variable thal (resultado del examen de flujo sanguíneo/talasemia).
 - Para el grupo de la derecha (pacientes con dolor torácico severo), el árbol utiliza la variable oldpeak (depresión del segmento ST), que mide el nivel de estrés y fatiga del miocardio durante el ejercicio.

3. Nivel de División 2 y Hojas Terminales (Nivel 3): En el último nivel antes de emitir el diagnóstico, el modelo refina la búsqueda utilizando variables de soporte como el número de vasos principales coloreados (ca), la frecuencia cardíaca máxima (thalach), el sexo biológico del paciente (sex) y la pendiente del segmento ST (slope). Al llegar al tercer nivel de profundidad, el algoritmo se detiene y asigna la etiqueta final en los nodos terminales u hojas, dictaminando si el paciente pertenece a la clase "Sano" o "Enfermo".

Este mapa visual demuestra que, aunque el Árbol de Decisión Regulado obtuvo un Accuracy menor (76.66%) que el Random Forest (83.33%) en validación, ofrece a cambio una interpretabilidad clínica absoluta. Esto permite que cualquier médico especialista pueda entender, revisar y auditar la ruta lógica detrás del diagnóstico automático del software.

5. Evaluación final y discusión

5.1. Desempeño Definitivo en el Conjunto de Prueba (Test)

Una vez completada la fase de experimentación y sintonización con los datos de validación, se seleccionó al Random Forest Regulado (`n_estimators=200`, `max_depth=3`) como el modelo definitivo del proyecto. Para obtener la mejor evaluación posible, enfrentamos al modelo ganador al conjunto de datos de prueba (Test), el cual representó un grupo de pacientes totalmente desconocidos para el algoritmo.

Las métricas obtenidas en el conjunto de prueba arrojaron los siguientes resultados:

- Accuracy (Exactitud): 0.8032 (80.32%)
- Precision (Precisión): 0.8387 (83.87%)
- Recall (Sensibilidad): 0.7878 (78.78%)
- F1-Score: 0.8125 (81.25%)

Análisis crítico de las métricas clínicas

El análisis del comportamiento demuestra una alta eficiencia algorítmica y una sólida consistencia estructural, lo cual se evidencia al desglosar sus métricas de rendimiento:

- **Estabilidad global y control de overfitting (Accuracy: 80.32%):** El hecho de que la exactitud general del modelo se haya mantenido en un 80.32% en el conjunto de prueba es clave. Este comportamiento confirma la estabilidad del modelo y demuestra que las técnicas de regularización aplicadas funcionaron de manera óptima, logrando que el

algoritmo mantenga intacta su capacidad predictiva al enfrentarse a registros completamente nuevos y aislados.

- **Control de falsos positivos (Precision: 83.87%):** Esta métrica indica que el modelo posee un estricto control sobre los errores de falsos positivos. Esto significa que cuando el sistema marca un paciente como positivo, existe una certeza del 83.87% de que dicha clasificación sea correcta, minimizando la generación de falsas alarmas en el sistema.
- **Tasa de recuperación de instancias (Recall: 78.78%):** El recall mide la sensibilidad del algoritmo frente a la clase objetivo, demostrando que el modelo logra identificar, recuperar y clasificar correctamente al 78.78% de los registros verdaderos del dataset. Esto asegura que el modelo es capaz de capturar la gran mayoría de los casos críticos sin omitirlos ni dejarlos pasar como falsos negativos.
- **Optimización y Balance del Sistema (F1-Score: 0.8125):** Al actuar como la media armónica entre la precisión y la sensibilidad, el F1-Score consolida un compromiso óptimo entre ambos frentes. Un valor de 0.8125 demuestra que el modelo es robusto, balanceado y simétrico, ya que no se encuentra sesgado hacia ninguna de las dos métricas, cumpliendo con el comportamiento ideal esperado para un sistema de clasificación binaria.

5.2. Tabla Comparativa General de Experimentos

Para visualizar de forma unificada el comportamiento de la investigación y cumplir con las exigencias de la pauta, se presenta la siguiente tabla resumen que consolida todos los experimentos desarrollados a lo largo del proyecto:

Modelo	Preprocesamiento	Hiperparametros	Conjunto	Accuracy	Precision	Recall/F1	Observación
Arbol de Decision (Base)	StandardScaler	max_depth=None	Validación	0.7500	0.7352	0.8333 / 0.7812	Presencia de overfitting severo
Arbol de Decision (Regulado)	StandardScaler	max_depth=3	Validación	0.7666	0.7500	0.8333 / 0.7894	Control de profundidad mitiga overfitting
Random Forest (Base)	StandardScaler	max_depth=None	Validación	0.7500	0.7575	0.7941 / 0.7753	Mantiene overfitting por falta de límites

Random Forest (Regulado)	StandardScaler	n_estimators=200, max_depth=3	Validación	0.8333	0.8485	0.8485 / 0.8485	Mejor rendimiento y balance general
Random Forest (Regulado / Test)	StandardScaler	n_estimators=200, max_depth=3	Prueba (Test)	0.8032	0.8387	0.7878 / 0.8125	Rendimiento final consistente y robusto

5.3. ¿Qué se gana y que se pierde?

La transición desde un modelo simple hacia un modelo de ensamble responde a una pregunta fundamental del proyecto: ¿Qué se gana y qué se pierde al pasar de un Árbol de Decisión a un Random Forest?

- **Lo que se gana:** Se gana una reducción drástica de la varianza y una estabilidad predictiva superior. Un árbol individual es sumamente sensible a los cambios. El Random Forest, al promediar el voto de 200 árboles independientes, neutraliza los errores individuales y los ruidos de la muestra, logrando controlar el overfitting y elevando el Accuracy al 80.32%.
- **Lo que se pierde:** Se pierde la capacidad de interpretación directa. Como se demostró en la Sección 4.3, el árbol individual se puede dibujar y revisar visualmente en una sola pantalla. En cambio, el Random Forest opera bajo una lógica de "caja negra", donde es humanamente imposible seguir el rastro a las decisiones simultáneas de 200 estructuras distintas, sacrificando explicabilidad a cambio de mayor precisión matemática.

5.4. Implicaciones Éticas y Limitaciones del Modelo en el Área de la Salud

La incorporación de sistemas de Inteligencia Artificial en la medicina exige un análisis ético riguroso y responsable. Nosotros creemos firmemente que estos modelos bajo ningún escenario deben buscar reemplazar el diagnóstico real de un médico profesional ni sustituir la toma de exámenes clínicos serios e instrumentales.

El valor real de este software se encuentra en actuar estrictamente como una herramienta de ayuda complementaria y de orientación preliminar. El sistema debe ser entendido y utilizado como un mecanismo de tamizaje primario; es decir, un primer paso accesible para que un usuario

comience a estudiar su estado de salud. Su función es encender alarmas tempranas basadas en sus síntomas y guiar al paciente de manera responsable para que acuda a un centro asistencial a realizarse exámenes diagnósticos de mayor precisión y especificidad con un especialista.

Considerar la predicción de un algoritmo como un veredicto final o definitivo sería una irresponsabilidad médica. Un error del modelo en forma de Falso Negativo podría causar que una persona ignore un riesgo cardíaco real. Por lo tanto, el uso de Machine Learning en salud debe mantenerse siempre en el plano del soporte y la prevención, dejando la responsabilidad de la toma de decisiones críticas exclusivamente en las manos del criterio médico humano.

6. Conclusiones

6.1. Cumplimiento de Objetivos y Validación Metodológica

El presente proyecto cumplió satisfactoriamente con el diseño e implementación de un sistema de aprendizaje supervisado para la clasificación de perfiles de riesgo cardíaco. Se logró validar que un flujo de trabajo estructurado, que incluya una limpieza rigurosa de datos, el escalado preventivo de atributos y una estrategia de partición de datos en tres conjuntos independientes, es la única garantía para desarrollar software predictivo confiable y auditable.

6.2. Hallazgos Técnicos sobre el Control de Overfitting

La experimentación demostró que la complejidad estructural es el factor determinante en el rendimiento de los modelos basados en árboles. Se concluye que el uso de algoritmos en sus configuraciones predeterminadas es inviable para entornos de producción, dada su tendencia natural a la memorización de datos. El hallazgo técnico más relevante fue comprobar que la restricción de la profundidad máxima (`max_depth=3`) actúa como el mecanismo de regularización más efectivo, logrando transformar modelos que sufrían de overfitting severo en clasificadores con una alta capacidad de generalización.

6.3. Recomendación del Modelo y Escalabilidad

Tras la evaluación comparativa, el Random Forest Regulado se consolida como el modelo recomendado para este problema de clasificación. Con un Accuracy del 80.32% y un F1-Score del 81.25% en el conjunto de prueba, el ensamble demostró una robustez superior al árbol

individual, logrando neutralizar el ruido de la muestra y proporcionando métricas balanceadas entre precisión y sensibilidad.

Finalmente, el diseño del sistema se considera altamente escalable. Gracias a la implementación del preprocesamiento con StandardScaler y la modularización del código en el entorno de Jupyter Notebook, la arquitectura queda preparada para integrar en el futuro una mayor volumetría de datos o algoritmos de mayor complejidad computacional, manteniendo siempre el enfoque ético de ser una herramienta de soporte complementaria para la salud pública.

6.4. Trabajo Futuro y Mejoras

Si se dispusiera de un mayor tiempo para la evolución y optimización de este proyecto, se proponen las siguientes mejoras metodológicas y técnicas:

- **Exploración de otros algoritmos:** Implementar y comparar modelos de distinta naturaleza matemática, tales como Máquinas de Vectores de Soporte (SVM) o Regresión Logística. Esto permitiría evaluar si modelos no basados en árboles ofrecen ventajas adicionales en la frontera de decisión clínica.
- **Ampliación de la volumetría de datos:** Gestionar e integrar un dataset con una cantidad significativamente mayor de registros (superando los 302 pacientes únicos actuales) y con mayor diversidad epidemiológica. Un mayor volumen de datos permitiría entrenar un modelo mucho más representativo a nivel global, reduciendo posibles sesgos poblacionales y acercando el sistema a un entorno de producción real.